



Proyecto Ciencia de datos - Preparación de Datos

Objetivo:

Aplicar los macroprocesos de preparación de datos dentro de un proyecto de ciencia de datos, garantizando la calidad, consistencia y adecuación para su posterior análisis.

Etapa 1 – Planeación y Recopilación

1. Seleccionar un conjunto de datos **propio o del portal [Datos Abiertos Colombia](#)**

Ejemplo: *Procesos de compra pública registrados en la plataforma SECOP I*

Requisitos del dataset:

- Mínimo 2000 registros.
 - Mínimo 12 atributos (Columnas)
 - El conjunto de datos **debe contener atributos continuos y discretos**.
 - Los registros deben tener datos incompletos o inconsistentes para su tratamiento. (si los datos están perfectos, no tendría sentido aplicar los macroprocesos de preparación de datos)
2. Identificar la fuente de datos y su pertinencia respecto al objetivo de negocio.
 3. Describir el contexto del problema a analizar (qué se busca analizar o resolver).
 4. **Formular una pregunta guía analítica** (por ejemplo: “¿Qué variables influyen en la tasa de abandono escolar?” o “¿Qué población es la más afectada por abandono escolar?”)

Etapa 2 – Exploración de datos

5. Cargar el dataset en la herramienta seleccionada (de libre elección)
6. Realizar el **análisis exploratorio** de los datos incluyendo como mínimo:
 - Tabla de diagnóstico de calidad de datos:
 - Porcentaje de valores nulos
 - Tipo de datos
 - Identificación de posibles outliers
 - Visualizaciones (mínimo 3)
 - Distribuciones
 - Relaciones entre variables
 - Análisis de Correlación. (Cuando aplique)

Nota: Cada visualización debe estar acompañada de su debida interpretación.



Etapa 3A – Limpieza de datos

7. Realizar el proceso de limpieza incluyendo:

- Detección y tratamiento de **valores faltantes**
- Detección y tratamiento de atributos con **valores únicos o distintos**. (baja variabilidad o alta cardinalidad)
- Detección y tratamiento de datos **atípicos e inconsistentes**
- Eliminación de duplicados (si aplica)

Todas las decisiones deben ser justificadas con base en los criterios establecidos (por ejemplo: eliminar atributos si faltan más del 50% de los datos)

Etapa 3B – Análisis de datos

- A partir de los datos procesados, generar conclusiones válidas y útiles que contribuyan al objetivo planteado. (No del uso práctico de la herramienta seleccionada, **el análisis debe ser sobre los datos y resultados obtenidos**)
- Responder la pregunta analítica
- Identificar patrones relevantes.

Se espera coherencia entre la pregunta analítica, el análisis realizado y las conclusiones obtenidas.

Etapa 4 – Creación de la vista minable

8. Construir una vista preparada para análisis posterior, **mínimo** incluir:

- **Normalización** de al menos un atributo
- **Discretización** de al menos un atributo
- **Numerización 1 a n** de al menos un atributo

Etapa 5 – Infografía final

9. Elaborar una infografía que comunique los principales hallazgos:

- Datos más relevantes **relacionados con el objetivo del negocio**. (La infografía **no se debe enfocar en el procedimiento**, enfocada en resultados)
- La infografía debe incluir al menos una visualización que evidencie patrones o relaciones encontradas, **acompañada de una breve interpretación** de los resultados.



Entrega completa en Brightspace:

1. El **documento** debe incluir: portada, introducción, objetivo, **desarrollo por etapas**, análisis de resultados y conclusiones generales. **La entrega deberá realizarse antes de las 11:59 p.m. del 25 de mayo en Brightspace.**
2. **Presentación (pdf o ppt):** En donde se mencione las etapas clave de la aplicación de los macroprocesos durante la preparación de los datos en relación con el objetivo de negocio identificado.
3. **Infografía** realizada. Se evaluará especialmente la **calidad del análisis e interpretación**, no únicamente la generación de gráficos.

Nota: *No subir los archivos en un archivo zip, se adjuntan ambos archivos en la entrega, la presentación también como un archivo, no un enlace. Se calificará el último envío.*

Herramientas sugeridas

- Python (Pandas, Matplotlib, Seaborn)
- R
- Power BI
- Altair AI Studio (Rapidminer)

Presentación de resultados

En la **semana 17 de clase**, se realizará una **exposición del proyecto entregado**, en donde se debe sustentar y mencionar los aspectos más relevantes del proyecto y la justificación de la **infografía generada. (Tiempo máximo de 10 min)**

La entrega se realizará en los grupos definidos previamente. **Todos los integrantes deben estar presentes en la sustentación (1.0 si no se asiste), si un integrante del grupo no aparece como autor en el documento subido a la plataforma su nota final será de 0.0.**